GoodWe Grid Assistant

Relatório de evolução das Sprints 1 a 4 | Implementação RAG HCA G2 | 21 de outubro de 2026

1. Contexto, objetivo e trajetória do projeto

O GoodWe Grid Assistant foi desenvolvido para apoiar a consulta a registros de recarga, falhas, consumo, faturamento e manutenção. A proposta combina **informações operacionais simuladas** com documentação técnica da linha GoodWe HCA G2, oferecendo respostas rastreáveis e recusando afirmações que não estejam sustentadas na base. O público principal é o gestor ou operador de eletropostos, com uso complementar por técnicos e administradores.

1.1. Evolução entre as quatro Sprints

Sprint	Solução e evolução técnica	Resultado / decisão
1 — Definição	Levantamento das personas, perguntas frequentes e intenções operacionais. Definição de escopo, fluxos e prompt-base.	Fundação do chatbot e limites do domínio.
2 — Aplicação	Protótipo funcional em Python/FastAPI e HTML, com gpt-oss:120b via Ollama Cloud, histórico e contexto operacional simulado.	68,75% de qualidade em 8 casos; latência média 2.457,38 ms.
3 — Engenharia	Refatoração modular com LCEL, memória por sessão, Pydantic v2, XML tagging, guardrails e JSON externo.	100% no mesmo mini-eval de 8 casos; latência média 876,98 ms.
4 — RAG	Ingestão de PDFs, embeddings, ChromaDB persistente, recuperação top-k, fontes citadas, interface Gradio e avaliação de duas configurações com revisão de segurança.	66 julgamentos humanos; versão final com 1,0000 em ambas as métricas no conjunto de 22 perguntas.

1.2. Antes e depois da arquitetura

Antes: o contexto operacional era apresentado como dados integrais ou texto fixo, e o histórico podia aumentar a quantidade de informações irrelevantes no prompt. **Depois:** documentos são indexados, recuperados por similaridade e disponibilizados ao modelo como trechos identificados; o sistema verifica a presença de fontes e preserva a separação de sessões. A evolução melhora a rastreabilidade das respostas e permite ampliar o conhecimento sem reescrever o prompt principal.

Os indicadores das Sprints 2 e 3 pertencem a um conjunto anterior de 8 perguntas. Eles descrevem a evolução do protótipo, mas não são diretamente comparáveis às notas RAG de 22 perguntas.

2. Arquitetura RAG e base de conhecimento

Fluxo de processamento: PDF / Markdown / JSON → PyMuPDFLoader e loaders → RecursiveCharacterTextSplitter → Nomic Embed v1.5 → ChromaDB → retriever top-k → prompt RAG + ChatOllama → validação das citações → Gradio.

Camada	Implementação e função
Documentos	**Datasheet HCA G2 (2 p.)**, **manual do usuário (70 p.)** e **mapa Modbus (9 p.)**; FAQ e procedimentos acadêmicos; `contexto_operacional.json` com registros simulados. O carregamento preserva metadados de origem, seção e página.
Embeddings	`nomic-ai/nomic-embed-text-v1.5`, com vetores de 768 dimensões executados via SentenceTransformers em Python local. O gerador gpt-oss:120b usa Ollama Cloud.
Persistência	Coleções ChromaDB distintas para iter1 e iter2. Os manifestos armazenam características da base e do perfil, evitando reutilização silenciosa de índices desatualizados.
Geração	Prompts versionados com instruções de grounding, documentos tratados como dados, formato de resposta e identificação de fontes `[F1]`, `[F2]` etc.
Validação	As referências citadas devem existir entre os trechos recuperados. Formatos equivalentes de citação são normalizados; sem fonte válida, ocorre uma segunda tentativa ou recusa.
Interface	Gradio com conversação e fontes exibidas. O servidor FastAPI/HTML anterior permanece disponível como componente histórico.

2.1. Estratégias comparadas no mesmo corpus

Configuração	Chunk / overlap	Top-k	Prompt / proteção
Iteração 1	400 / 40 caracteres	3	`rag_v1.md`: grounding e citações básicos
Iteração 2	750 / 100 caracteres	4	`rag_v2.md`: contexto estruturado, regras de recusa e citações
I2 + segurança v2	750 / 100 caracteres	4	Mesmo RAG da I2; política adicional contra manutenção energizada

A indexação ampliada carregou **113 documentos por perfil** e produziu **349 chunks na I1** e **216 chunks na I2**. O chunk maior preserva relações entre sentenças, enquanto o top-k maior amplia o contexto disponível; as duas mudanças ocorreram juntamente com a revisão do prompt, de modo que o efeito individual de cada ajuste não pode ser isolado.

2.2. Documentação do fabricante e limites de inferência

O HCA G2 abrange GW7K-HCA-20 (7 kW), GW11K-HCA-20 (11 kW) e GW22K-HCA-20 (22 kW). O mapa Modbus descreve o registrador **10015** para potência, mas não fornece leituras atuais. Identificadores como GW-03 e GW-09 são **estações simuladas**, não códigos de modelo. O corpus não contém regimento condominial ou tarifa contratual por kWh; o faturamento semanal de R$ 18.420,00 é apenas um registro simulado.

3. Método de avaliação e evidência de ganho

Foram utilizadas **22 perguntas idênticas em cada execução**: 14 operacionais (R01–R14) e 8 técnicas HCA G2 (H01–H08). O conjunto cobre respostas factuais, procedimentos, registros ausentes, tentativa de prompt injection, limites do equipamento e segurança elétrica. Ao todo, foram realizados **66 julgamentos humanos** sobre três versões.

3.1. Rubrica e registro

Métrica	Critério de pontuação
Faithfulness	Verifica se os fatos afirmados são sustentados pelos trechos recuperados. Nota 1: sustentação integral ou recusa adequada sem inventar fatos; 0,5: extrapolação parcial; 0: afirmação sem base.
Answer relevancy	Mede a adequação da resposta à pergunta, incluindo recusas justificadas. Nota 1: atendimento completo; 0,5: atendimento parcial ou recusa pouco informativa; 0: resposta inadequada.

As pontuações são calculadas como média aritmética das 22 notas individuais por métrica. Trata-se de **avaliação humana documentada**, não de score gerado pelo RAGAS. Os registros de execução confirmaram corpus válido, mesmas perguntas e 22 avaliações completas por versão.

3.2. Resultados medidos

Versão	Faithfulness	Answer relevancy	Casos
I1 — RAG v1	**0,9773**	**0,9773**	22 / 22
I2 — RAG v2	**1,0000**	0,9773	22 / 22
I2 + segurança v2	**1,0000**	**1,0000**	22 / 22

Ganho final frente à I1: +0,0227 na escala 0–1, equivalente a +2,27 pontos percentuais em cada métrica. Na comparação I1→I2, somente faithfulness melhorou; a terceira etapa foi necessária para elevar answer relevancy. O corpus e as configurações do retriever foram mantidos na revisão de segurança.

3.3. Análise qualitativa dos casos decisivos

Caso	Evidência e interpretação
R07 — RFID	A I1 afirmou preenchimento automático de todos os campos após leitura do cartão, sem respaldo documental: faithfulness 0,5. A I2 restringiu-se aos campos de registro e ao vínculo RFID: 1,0.
R14 — Segurança	I1 e I2 recusaram de forma genérica a abertura de GW-09 energizada: relevancy 0,5. A segurança v2 bloqueou o procedimento, alertou sobre choque elétrico e orientou técnico habilitado: 1,0.
R09–R11, H07–H08	Recusas corretas para tarifa, tensão em tempo real, potência exata de estação simulada, leitura atual do Modbus e preço definido por condomínio.
R12–R13	Guardrails interromperam instrução maliciosa para inventar tarifa e consulta fora do escopo do assistente.

A avaliação representa o comportamento observado nesse conjunto controlado. As coletas integrais permanecem no ambiente local porque incluem trechos dos documentos; o repositório contém métricas agregadas e as 66 pontuações resumidas.

4. Comparação de modelos, segurança e testes

4.1. Geração e parâmetros

O gerador principal do experimento HCA G2 é o **gpt-oss:120b** via ChatOllama. A geração RAG utiliza temperatura efetiva **0**, `top_p=0,9` e limite de **350 tokens**. A comparação adicional entre modelos avaliou `gpt-oss:120b` e `gpt-oss:20b` no **corpus anterior à inclusão dos PDFs HCA**, com 14 questões e o mesmo perfil de recuperação.

Indicador histórico — 14 casos	gpt-oss:120b	gpt-oss:20b
Casos processados	14 / 14	14 / 14
Latência média	1.594,76 ms	1.669,64 ms
Citação visível nas saídas	50,0%	50,0%

Essa comparação documenta viabilidade, tempo observado e formato das saídas; **14/14 processados não implica 14 respostas corretas**. Como o corpus difere daquele das 22 perguntas HCA G2, os números não são tratados como desempenho atual de ambos os modelos. O experimento principal compara duas estratégias RAG com o mesmo gerador.

4.2. Problemas encontrados e soluções aplicadas

Desafio	Solução técnica adotada
Contexto e histórico	Memória conversacional delimitada por sessão; recuperação de trechos relevantes em lugar do contexto completo apresentado a cada pergunta.
Fontes e citações	Normalização de `[Referência: F1]` e `□F1□` para `[F1]`, aceitação somente de IDs recuperados e segunda tentativa controlada quando falta referência.
Injeção e desvio de escopo	Instruções de documentos tratadas como dados; guardrails específicos para tentativas adversariais e solicitações fora das funções do assistente.
Manutenção energizada	Novo bloqueio de pedidos para abrir ou trocar componentes com energia ativa; a resposta enfatiza risco, suspensão do uso e intervenção profissional.
Valores e sensores ausentes	Distinção entre documentação de fábrica e telemetria real; recusa de tarifa contratual e medidas que não estejam no corpus.

4.3. Validação técnica

A versão revisada passou em **42 de 42 testes automatizados**, incluindo guardrails, tratamento de citações, importação HCA G2 e verificações de integridade. A coleta final `hca_safety` processou **22/22 questões**: 14 respostas aceitas, 5 recusas do modelo e 3 recusas do guardrail, sem `RuntimeError` nem falhas de citação. O julgamento humano complementou os testes de código.

5. Organização, entregáveis e conclusão

5.1. Organização da equipe

Integrante / RM	Frente de desenvolvimento
Felipe Mitsuo Takahashi Stephano — 570692	Pipeline RAG/LCEL e integração com ChatOllama.
Felipe Perdigão Macedo — 570990	Interface Gradio, memória por sessão e experiência de uso.
Laura Godoy Callegari — 569181	Corpus documental, embeddings Nomic e persistência ChromaDB.
Letícia Araújo Espindola — 569308	Chunking, prompts versionados, grounding e citações.
Mariana Dreset Carbollan — 569207	Guardrails, intervenção elétrica e testes de segurança.
Milena de Aguiar Lopes Cardoso — 570599	Rubrica de avaliação, métricas, comparação e relatório.

5.2. Componentes e rastreabilidade da entrega

Elemento	Arquivo ou evidência
RAG e base persistente	`src/rag/`, `scripts/importar_hca_g2.py`, `data/knowledge_base/` e perfis versionados.
Interface e segurança	`app/gradio_app.py`, `src/guardrails/`, `src/rag/service.py`, suíte `tests/`.
Avaliação e métricas	`evals/resultado_sprint4_hca_safety.json`, `evals/notas_resumidas_publicaveis_hca.json`, `docs/relatorio_rag_hca_seguranca_v2.md`.
Comparação de modelos	`docs/relatorio_modelos.md`, `evals/comparativo_modelos_iter2.json`, perfis em `prompts/versoes_rag.md`.
Execução e relatório	`README.md`, `README_SPRINT4_VSCODE.md`, `scripts/validar_entrega.py`, relatório consolidado PDF.

5.3. Síntese dos resultados

A Sprint 4 transformou o protótipo conversacional em um assistente com **RAG persistente, referências documentais, interface web e avaliação sistemática**. O ganho final de **97,73% para 100% nas duas métricas**, no conjunto fixo de 22 perguntas, foi acompanhado por uma melhoria concreta: a orientação explícita contra intervenção em equipamento energizado. O projeto conserva tanto os componentes funcionais das Sprints anteriores quanto os registros das três etapas do experimento.

A aplicação utiliza fontes de fabricante para especificações dos modelos HCA G2 e dados simulados para operações de estações. Permanecem fora do escopo a telemetria em tempo real, regras contratuais de condomínio e precificação sem documentos verificáveis. O uso de embeddings Nomic via Python local é distinto do provedor Ollama Cloud empregado para geração.

Referências técnicas: manual GoodWe HCA G2 V1.5 (2025-11-11), ficha HCA G2 e mapa Modbus HCA G2 fornecidos para uso local; informações simuladas em `contexto_operacional.json`; critérios da rubrica em `evals/RUBRICA.md`.